

forgery_detection_data_pipeline_report

基于六篇文献的伪造检测数据集构建 Pipeline 汇报文档

汇报主题：从 GIM、MIML、TruFor、HiFi-Net、FakeShield、Community Forensics 六篇论文中提炼数据集构建方法，并设计适用于图像伪造检测与定位任务的数据 pipeline。
适用任务：AI 生成图像检测、局部篡改定位、AIGC 编辑检测、跨生成器泛化评估、可解释图像取证。

1. 汇报摘要

当前图像伪造检测任务正在从传统的 splicing、copy-move、object removal 等局部编辑，扩展到 AIGC 整图生成、AIGC 局部重绘、文本驱动编辑和多模态可解释取证。六篇论文分别从不同角度解决数据集构建问题：

- **GIM**：构建百万级 AIGC 局部生成式篡改数据集，重点解决生成式图像编辑检测与定位。
- **MIML**：从互联网真实人工篡改图像中自动生成像素级 mask，重点解决真实风格图像篡改定位数据不足。
- **TruFor**：强调真实图像噪声、相机指纹和后处理痕迹，提示数据集中应保留真实图像来源与退化链路。
- **HiFi-Net**：提出层级细粒度伪造属性标注，提示数据集不应只有真假标签，还应有多层次伪造类型标签。
- **FakeShield**：将图像取证扩展为可解释任务，提示数据集可以加入文本解释、篡改依据和区域描述。
- **Community Forensics**：用数千个生成器构建跨生成器检测数据，证明生成器多样性是泛化能力的关键。

因此，我的数据 pipeline 应围绕以下五类数据构建：

1. **真实图像池**：提供真实负样本和篡改底图。
2. **整图 AIGC 生成数据**：用于训练整图真假检测器。
3. **局部 AIGC 篡改数据**：用于训练像素级定位模型。
4. **真实网页人工篡改数据**：用于提升真实编辑场景泛化。
5. **可解释取证子集**：用于训练模型输出文字解释和判断依据。

2. 六篇论文的数据集构建方法提炼

论文	数据构建对象	关键构建方法	对本 pipeline 的启发
GIM	AIGC 局部生成式篡改数据	用真实图像作为底图；SAM 生成局部 mask；LLM 生成编辑 prompt；Stable Diffusion、GLIDE、DDNM 等模型生成局部替换或删除结果；保存 fake image 与 mask；设计 mix-generator 和 cross-generator 测试集	构建 局部 AIGC 篡改定位数据 ，必须记录 mask、prompt、生成器、编辑类型和后处理参数
MIML	真实网页人工篡改图像	从网页收集真实图像与人工篡改图像 pair；使用 CAAA 自动生成像素级标注；用 QES 质量评价过滤低质量 mask	构建 真实人工编辑风格数据 ，重点是从真实 pair 自动蒸馏 mask，而不是单纯合成
TruFor	通用图像伪造检测/定位训练数据	利用真实相机图像学习 Noiseprint++；结合 RGB 语义线索与低层噪声指纹；训练时关注图像篡改区域与可靠性图	单独维护 真实相机图像池 ，保留 EXIF、相机型号、压缩质量、resize 等真实取证线索
HiFi-Net	层级细粒度伪造数据	构建覆盖多种伪造方法的数据集；为样本提供 mask 和层级伪造属性标签，如整图生成/局部篡改、Diffusion/GAN/CNN、具体方法等	建立 层级标签体系 ，让模型不仅学习 fake/real，还学习伪造来源、方式和细粒度类型
FakeShield	可解释图像伪造检测数据	从 Photoshop、DeepFake、AIGC-Editing 等数据集中采样 image-mask pair；使用 GPT-4o 等 MLLM 生成篡改解释；形成 image-mask-description 三元组	构建 可解释取证子集 ，保存文字解释、篡改区域描述和伪迹依据
Community Forensics	跨生成器 AI 图像检测数据	收集数千个生成器；每个生成器生成少量图像；覆盖开源模型、商业模型和不同生成架构；与真实图像配对训练	构建 跨生成器整图检测数据 ，重点不是单模型大量采样，而是覆盖足够多生成器


3. 数据 pipeline 总体设计

建议将数据集拆成五个子库，避免不同任务混杂：

D0_real_pristine	真实图像池
D1_whole_generated	整图 AIGC 生成库
D2_local_aigc_edit	局部 AIGC 篡改库

D3_web_human_forgery 网页真实人工篡改库
D4_explainable_subset 可解释取证子集

整体 pipeline 如下：



4. 子库一：真实图像池 D0_real_pristine

4.1 目标

真实图像池承担三类功能：

1. 作为真实负样本，用于训练 fake/real 二分类模型。
2. 作为局部篡改底图，用于生成 AIGC 局部编辑数据。
3. 作为真实相机/噪声/压缩痕迹学习数据，用于提升模型对真实图像分布的理解。

4.2 数据来源

推荐来源：

- 自然图像：COCO、ImageNet、OpenImages、Places、业务域图像。
- 人脸图像：FFHQ、CelebA-HQ、YouTube Face 等。
- 真实相机图像：Flickr、DPReview、VISION、自采手机/相机图像。
- 场景图像：新闻图、电商图、社交媒体图、截图图像等。

4.3 清洗规则

1. 删除解码失败图像。
2. 删除极小分辨率图像，建议短边 ≥ 256 。
3. 删除极端长宽比图像。
4. 使用 pHash / CLIP embedding 去重。
5. 标记并区分水印、截图、边框、拼图图像。
6. 尽量保留 EXIF、相机型号、分辨率、压缩质量等元数据。
7. 记录 license，区分可训练、仅评估、不可再分发数据。

4.4 输出字段

```
{
  "image_id": "real_000001",
  "image_path": "D0_real_pristine/real_000001.jpg",
  "is_fake": 0,
  "source_dataset": "COCO",
  "camera_model": null,
  "resolution": [1024, 768],
  "license": "research-only",
  "split_candidate": "train"
}
```

5. 子库二：整图 AIGC 生成数据 D1_whole_generated

5.1 目标

训练模型识别整张图是否由 AI 生成，并评估模型对未知生成器的泛化能力。

5.2 构建原则

Community Forensics 的核心启发是：

与其从少数生成器中采集海量图像，不如从大量不同生成器中各采集适量图像。

因此，D1 应优先追求 **生成器多样性**。

5.3 生成器覆盖范围

建议覆盖以下类型：

1. Diffusion models
 - Stable Diffusion 1.x / 2.x
 - SDXL
 - FLUX
 - OpenJourney
 - Anything / RealisticVision / DreamShaper 等社区模型
2. 商业闭源模型
 - Midjourney
 - DALL·E
 - Adobe Firefly
 - Ideogram
3. GAN models
 - StyleGAN
 - BigGAN
 - ProGAN
4. 其他生成架构
 - autoregressive models
 - consistency models
 - image-to-image models

5.4 Prompt 构建

Prompt 来源可以包括：

- 1. COCO captions
- 2. LAION captions
- 3. 业务场景 prompt
- 4. LLM 自动扩写 prompt
- 5. 人工设计 prompt 模板

Prompt 示例：

A realistic photo of a dog running on the beach at sunset.
A news-style photo of a crowded street after heavy rain.
A product photography image of a black backpack on a white background.

5.5 推荐规模

版本	生成器数量	每个生成器图像数	总规模
MVP	50–100	200	10k–20k
标准版	500–1000	200–500	100k–500k
大规模版	3000+	200–500	600k+

5.6 输出字段

```
{
  "image_id": "whole_gen_000001",
  "image_path": "D1_whole_generated/whole_gen_000001.png",
  "is_fake": 1,
  "task_type": "whole_image_detection",
  "manipulation_level1": "whole_generated",
  "manipulation_level2": "diffusion",
  "generator_name": "stable-diffusion-xl",
  "generator_family": "diffusion",
  "prompt": "A realistic photo of a dog running on the beach at sunset.",
  "negative_prompt": "low quality, blurry",
  "seed": 12345,
  "sampler": "DPM++ 2M",
  "steps": 30,
  "cfg_scale": 7.5,
  "mask_path": null
}
```


6. 子库三：局部 AIGC 篡改数据 D2_local_aigc_edit

6.1 目标

构建用于图像篡改定位的数据，即模型不仅判断图像是否为假，还要输出篡改区域 mask。

6.2 构建流程

借鉴 GIM，流程如下：



6.3 篡改类型设计

建议至少覆盖以下七类：

篡改类型	说明	示例
Object insertion	插入新物体	在桌子上添加一只杯子
Object replacement	替换物体	将狗替换为猫
Object removal	删除物体	移除路上的行人
Attribute editing	改变属性	改变衣服颜色、车辆颜色
Background editing	背景重绘	将室内背景改为海边
Text editing	图中文字修改	修改广告牌文字、证件文字
Face editing	人脸局部编辑	改变表情、眼镜、发型

6.4 Mask 生成与过滤

推荐规则：

1. 使用 SAM / Grounded-SAM 生成候选 mask。
 2. 过滤过小区域：mask_area_ratio < 1% 删除。
 3. 过滤过大区域：mask_area_ratio > 50% 删除。
 4. 保留小、中、大不同尺度区域：
 - 小目标：1%-5%
 - 中目标：5%-20%
 - 大区域：20%-50%
 5. 对 mask 做形态学扰动：
 - dilation
 - erosion
 - boundary blur
 - irregular mask
 6. 记录 mask 来源：SAM、Grounded-SAM、manual、synthetic。

6.5 Prompt 自动生成

可以用 LLM 根据图像类别和 mask 区域生成 prompt。

示例模板：

Given an image containing {object}, generate an editing instruction that replaces the masked region with a semantically plausible but different object.

输出示例：

Replace the dog in the masked region with a realistic orange cat sitting in the same pose.

Remove the person in the masked region and fill the background naturally.
Change the color of the car in the masked region from red to blue.

6.6 输出字段

```
{
  "image_id": "local_edit_000001",
  "real_image_path": "D0_real_pristine/real_00123.jpg",
  "image_path": "D2_local_aigc_edit/local_edit_000001.jpg",
  "mask_path": "D2_local_aigc_edit/masks/local_edit_000001.png",
  "is_fake": 1,
  "task_type": "localization",
  "manipulation_level1": "partial_manipulated",
  "manipulation_level2": "aigc_editing",
  "manipulation_level3": "object_replacement",
  "generator_name": "stable-diffusion-inpaint",
  "mask_source": "SAM",
  "prompt": "Replace the dog with a realistic orange cat.",
  "mask_area_ratio": 0.12,
  "quality_score": 0.86
}
```

7. 子库四：真实网页人工篡改数据 D3_web_human_forgery

7.1 目标

弥补纯合成数据与真实人工编辑图像之间的域差异。


MIML 的核心启发是：真实互联网中的人工篡改图像非常丰富，但缺乏 mask。可以通过自动标注和质量过滤，从网页 image pair 中构建大规模定位数据。

7.2 数据来源

可收集以下类型：

1. before-after Photoshop examples
2. 图像编辑教程网站
3. 社交媒体修图案例
4. 新闻事实核查网站
5. 图像篡改挑战数据
6. 用户上传的业务场景图像 pair

7.3 自动标注流程



7.4 工程近似版 CAAA

如果短期内不完整复现 MIML，可以采用以下近似流程：

- 1. 对 real-fake pair 做图像配准。
- 2. 计算 RGB 差分图、SSIM 差分图和 LPIPS 差异图。
- 3. 融合差异图得到 coarse mask。
- 4. 使用语义分割模型去除无关背景变化。
- 5. 使用 SAM 对 coarse mask 做边界细化。
- 6. 使用连通域分析删除噪声区域。
- 7. 得到 pseudo mask。

7.5 QES-like 质量过滤指标

建议构造一个质量评分：

```
quality_score = 0.3 * confidence
               + 0.2 * boundary_sharpness
               + 0.2 * mask_consistency
               + 0.2 * semantic_consistency
               + 0.1 * area_validity
```

其中：

指标	含义
confidence	自动分割模型或差异模型的平均置信度
boundary_sharpness	mask 边界是否清晰
mask_consistency	mask 与 real-fake 差异区域是否一致
semantic_consistency	mask 是否落在语义合理对象或区域上
area_validity	mask 面积比例是否合理

过滤建议：

```
quality_score >= 0.75: 进入训练集
0.60 <= quality_score < 0.75: 进入待人工复核池
quality_score < 0.60: 删除
```

8. 子库五：可解释取证子集 D4_explainable_subset


8.1 目标

让数据支持可解释伪造检测，即模型能够输出：

- 1. 真假判断。
- 2. 篡改区域 mask。
- 3. 篡改位置描述。
- 4. 篡改依据说明。
- 5. 可能的伪造类型。

8.2 构建流程

借鉴 FakeShield：



8.3 文本解释模板

建议统一文本字段格式：

```
{  
  "location_description": "The manipulated region is located in the lower-left
```

```
part of the image.",
  "visual_artifact_description": "The object boundary appears overly smooth
and inconsistent with the surrounding texture.",
  "semantic_reasoning": "The lighting direction of the inserted object does
not match the rest of the scene.",
  "forensic_conclusion": "The image is likely manipulated by local AIGC
inpainting."
}
```

8.4 中文汇报版解释示例

该图像的可疑区域位于画面左下角。该区域边缘纹理过于平滑，与周围背景的噪声分布和光照方向不一致。结合区域形状和内容变化，推测该图像可能经过局部 **AIGC** 重绘或对象替换。

9. 统一标签体系设计

借鉴 HiFi-Net，建议采用层级标签，而不是单一 fake/real 标签。

Level 0: real / fake

Level 1:

- whole_generated
- partial_manipulated

Level 2:

- diffusion
- GAN
- autoregressive
- Photoshop/editing
- DeepFake
- AIGC-editing
- copy-move
- splicing
- removal

Level 3:

- conditional_generation
- unconditional_generation
- text_guided_editing
- image_guided_editing
- mask_guided_inpainting
- object_replacement

- object_removal
- face_swap
- text_editing

Level 4:

- exact generator or method
- stable-diffusion-inpaint
- GLIDE
- DDNM
- Midjourney-v6
- DALL-E-3
- Photoshop-splicing

该标签体系可支持多任务训练：

```
loss = detection_loss
      + localization_loss
      + manipulation_type_loss
      + generator_family_loss
      + optional_explanation_loss
```

10. 后处理增强设计

真实互联网传播会破坏伪造痕迹，因此训练和测试都要包含后处理退化。

10.1 后处理类型

1. JPEG compression
 - quality: 50 / 60 / 70 / 80 / 90 / 95
2. Resize
 - scale: 0.5 / 0.67 / 0.75 / 1.5
3. Gaussian blur
 - kernel size: 3 / 5
4. Gaussian noise
 - sigma: 3 / 5 / 10
5. Social media compression
 - 微信/微博/X/Instagram 等平台转码

6. Screenshot recapture

- 屏幕截图或拍屏重采样

7. Metadata stripping

- 删除 EXIF 信息

10.2 推荐保存方式

```
image_original  
image_jpeg_q70  
image_resize_0.5  
image_blur_k3  
image_social_compressed
```

不要只保存处理后的图像，应同时保留原始 fake 图和后处理参数，便于做鲁棒性评估。

11. 质量控制 QC 设计

11.1 图像质量过滤

1. 图像能正常解码。
2. 短边 ≥ 256 。
3. 无大面积黑边、白边或纯色区域。
4. 图像内容不重复。
5. 图像 license 合法。

11.2 Mask 质量过滤

1. $0.01 \leq \text{mask_area_ratio} \leq 0.50$ 。
2. mask 不应过于碎片化。
3. mask 边界与图像变化区域基本一致。
4. mask 不应覆盖整张图，除非任务是整图生成。
5. 随机抽样人工复核。

11.3 生成质量过滤

1. 删除明显生成失败图像。
2. 删除 prompt 与图像内容严重不一致图像。
3. 删除局部编辑后产生明显大面积畸变的图像。
4. 保留一小部分低质量 AIGC，但需要单独标注 quality_bucket。

11.4 数据泄漏检查

- 1. 原图不能同时出现在 `train` 和 `test`。
- 2. 同一生成图的不同压缩版本不能跨 `split`。
- 3. 同一 `prompt + seed` 结果不能跨 `split`。
- 4. `cross-generator test` 中生成器不能出现在 `train`。
- 5. 公开 `benchmark` 图像不能混入训练集。

12. 数据划分方案

伪造检测数据集不能简单随机划分，必须设计多种评测集。

Split	目标	构建方法
Train	常规训练	seen images、seen generators、seen manipulation types
Val	调参	与 train 同分布，但图像不重复
Test-A In-domain	常规性能	seen generator family，unseen images
Test-B Cross-generator	泛化评估	完全未见过的生成器
Test-C Cross-manipulation	新篡改类型评估	train 不含某类篡改，test 专门测试该类
Test-D Cross-domain	跨场景评估	新闻图、电商图、社交媒体图、证件图等
Test-E Degradation	鲁棒性评估	JPEG、resize、blur、noise、社交平台压缩
Test-F Real-only	误报率评估	全部真实图像，测试 false positive rate

12.1 推荐划分策略

- 1. 按原图 `ID` 分组划分，避免同源泄漏。
- 2. 按生成器划分 `cross-generator` 测试集。
- 3. 按篡改类型划分 `cross-manipulation` 测试集。
- 4. 按后处理类型划分 `degradation` 测试集。
- 5. 保留全真实测试集，用于测误报率。

13. 统一 manifest 设计

建议所有数据统一写入 JSONL，每行一个样本。

13.1 完整字段

```
{
  "image_id": "sample_000001",
  "image_path": "images/sample_000001.jpg",
  "real_image_path": "real/real_000001.jpg",
  "mask_path": "masks/sample_000001.png",
  "is_fake": 1,
  "task_type": "localization",
  "manipulation_level1": "partial_manipulated",
  "manipulation_level2": "aigc_editing",
  "manipulation_level3": "object_replacement",
  "manipulation_level4": "stable-diffusion-inpaint",
  "source_dataset": "COCO",
  "generator_name": "stable-diffusion-inpaint",
  "generator_family": "diffusion",
  "prompt": "Replace the dog with a realistic orange cat.",
  "negative_prompt": "low quality, blurry",
  "seed": 12345,
  "sampler": "DPM++ 2M",
  "steps": 30,
  "cfg_scale": 7.5,
  "mask_source": "SAM",
  "mask_area_ratio": 0.12,
  "postprocess": {
    "jpeg_quality": 85,
    "resize": "none",
    "blur": "none",
    "noise": "none"
  },
  "quality_score": 0.86,
  "quality_bucket": "high",
  "split": "train",
  "license": "research-only",
  "explanation": {
    "location_description": "The manipulated region is in the center of the image.",
    "visual_artifact_description": "The object boundary is smoother than the surrounding texture.",
    "semantic_reasoning": "The lighting of the inserted object is inconsistent with the scene.",
    "forensic_conclusion": "The image is likely manipulated by local AIGC inpainting."
  }
}
```

13.2 MVP 必需字段

如果短期实现，至少保留以下字段：

```
image_id
image_path
real_image_path
mask_path
is_fake
task_type
manipulation_level1
manipulation_level2
generator_name
source_dataset
prompt
postprocess
quality_score
split
```

14. 推荐 MVP 实施方案

14.1 第一阶段规模

数据类型	规模建议	作用
真实图像	50k	真实负样本和篡改底图
整图 AIGC	10k–20k	整图生成检测
局部 AIGC 篡改	20k	像素级定位
网页人工篡改	5k–10k	真实编辑泛化
可解释子集	1k–3k	解释型取证实验

总规模约为：**80k–150k**。

14.2 第一阶段优先级

- P0：搭建真实图像池 D0。
- P1：构建整图 AIGC 数据 D1。
- P2：构建局部 AIGC 篡改数据 D2。
- P3：加入层级标签和 manifest。
- P4：设计 cross-generator 测试集。

P5: 补充网页人工篡改数据 D3。

P6: 构建可解释取证子集 D4。

14.3 第一阶段必须避免的问题

1. 只用少数生成器，导致模型记住生成器指纹。
2. 只做真假标签，没有 **mask** 和篡改类型标签。
3. **train/test** 随机划分，造成原图或生成器泄漏。
4. 忽略 **JPEG**、**resize**、社交平台压缩等真实传播退化。
5. 不记录 **prompt**、**seed**、**generator**、后处理参数，导致数据不可追溯。

15. 最终可汇报结论

基于六篇论文，可以总结出伪造检测数据集构建的五条核心原则：

1. **数据来源要多样**：既要有真实图像，也要有整图生成图、局部编辑图和网页人工篡改图。
2. **生成器要多样**：跨生成器泛化主要依赖生成器覆盖度，而不是单个生成器的样本数量。
3. **标注要层级化**：不能只标真假，还应标整图/局部、生成/编辑、方法类别和具体模型。
4. **定位数据要有高质量 mask**：局部篡改数据必须保存像素级 mask，并通过质量评分过滤。
5. **评测要模拟开放世界**：测试集必须包含未知生成器、未知篡改类型、未知后处理和全真实误报测试。

因此，本文设计的数据 pipeline 可以概括为：

真实图像池

- 整图生成 / 局部编辑 / 网页人工篡改
- 统一层级标签与 **manifest**
- **mask** 与质量控制
- 后处理增强
- **cross-generator** / **cross-domain** / **degradation** 测试集
- 训练检测、定位、分类和可解释取证模型

该 pipeline 同时吸收了：

- **GIM** 的 AIGC 局部篡改生成方式；
- **MIML** 的真实网页篡改自动标注思想；
- **TruFor** 的真实相机痕迹与后处理意识；
- **HiFi-Net** 的层级细粒度标签体系；
- **FakeShield** 的可解释文本标注；
- **Community Forensics** 的跨生成器数据多样性原则。

最终目标不是构建一个单一任务数据集，而是构建一个能够支持 **检测、定位、泛化评估和解释型取证** 的统一伪造检测数据基础设施。

16. 参考文献

- [1] Chen et al., *GIM: A Million-scale Benchmark for Generative Image Manipulation Detection and Localization*, AAAI 2025.
- [2] Qu et al., *Towards Modern Image Manipulation Localization: A Large-Scale Dataset and Novel Methods*, CVPR 2024.
- [3] Guillaro et al., *TruFor: Leveraging All-Round Clues for Trustworthy Image Forgery Detection and Localization*, CVPR 2023.
- [4] Guo et al., *Hierarchical Fine-Grained Image Forgery Detection and Localization*, CVPR 2023.
- [5] Xu et al., *FakeShield: Explainable Image Forgery Detection and Localization via Multi-Modal Large Language Models*, ICLR 2025.
- [6] Park and Owens, *Community Forensics: Using Thousands of Generators to Train Fake Image Detectors*, CVPR 2025.