

forgery-pipeline

# 伪造检测数据管线 真实扩散信号闸门实验

Real Diffusion Signal Gate Experiment

组会汇报 · 2026-07-02

---

# 一页结论:四道闸门判定

|                                                                                     |                                                                                             |                                                                             |                                                                       |
|-------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------|-----------------------------------------------------------------------|
| <div>GATE0</div> <div>PASS</div> <div>残差可分</div> <div>检测 AUC 0.688 · 定位 0.643</div> | <div>GATE1</div> <div>WEAK</div> <div>t<sub>0</sub> 可恢复</div> <div>BA 0.475 · p 0.476</div> | <div>GATE2</div> <div>WEAK</div> <div>算子可分</div> <div>0.372 vs 随机 0.2</div> | <div>GATE3</div> <div>PARTIAL</div> <div>多σ增量</div> <div>+0.025</div> |
|-------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------|-----------------------------------------------------------------------|

|                                                                                                                                                                  |
|------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <div>关键判断</div> <div><div>› 承重主线「残差可检测 / 可定位」在真实扩散信号下成立</div><div>› t<sub>0</sub> 精细回归被 mock 高估 (+0.28)，需降级为分桶方案</div><div>› mock 验证可保代码通路正确，不可估计效应量</div></div> |
|------------------------------------------------------------------------------------------------------------------------------------------------------------------|

# 背景:方法与闸门体系

## METHOD

### 冻结扩散先验的 多 $\sigma$ Tweedie 去噪残差

- 冻结预训练 Stable Diffusion 作为信号提取器
- 多强度 ( $\sigma$ ) Tweedie 去噪  $\rightarrow$  残差信号
- 下游任务:伪造检测 / 定位 / 强度估计
- 核心假设:伪造区域残差统计显著可分

## GATE SYSTEM

### 5 道 Go/No-Go 闸门

- gate0 残差可分性 (检测 + 定位)
- gate1  $t_0$  可恢复性 (强度回归)
- gate2 算子可分性 (生成器指纹)
- gate3 多 $\sigma$  增量 (信号增益)
- gate4 端到端管线泛化

⚠ 此前 VERDICT 全部基于 mock 数据 + CPU 代理  
仅验证代码通路,未验证假设



# 今日工作总览

上午

ROUND 1

P0 分析代码优化

+ Mock 复测

▪ 区域 / 分位特征工程

▪ 回归 → 分桶 (降级方案)

▪ 评测口径修复

▪ Bootstrap CI 置信区间

目标: 验证分析代码改进 → mock 指标变化



下午→晚间

ROUND 2

真实扩散闸门

SD1.5 · RTX 4060

▪ SD1.5 真实后端 (img2img + inpaint)

▪ 真实底图 (picsum 64 张 512²)

▪ n\_base=4 冒烟 → n\_base=50 放量

▪ 生成 80 min + 分析 30 min

目标: 真实信号下验证闸门假设

# 第一轮:Mock 复测结果

同数据 · 仅换分析代码

| Gate  | 旧值     | 新值     | 变化              | 判定   |
|-------|--------|--------|-----------------|------|
| gate1 | 0.472  | 0.757  | 回归→分桶           | PASS |
| gate2 | 0.330  | 0.454  | $\Delta$ +0.124 | WEAK |
| gate3 | +0.132 | +0.417 | $\Delta$ +0.285 | PASS |
| gate4 | 无定义    | 0.537  | 新增 CI           | EVAL |

！ 教训:mock 的 PASS 只说明代码口径对,不说明假设成立

# 第二轮:真实扩散实验设置

|                                                                                                                                                                 |                                                                                                                                                                                 |                                                                                                                                                                                                                                |                                                                                                                                                                  |
|-----------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <div><div>HARDWARE</div><div>硬件</div><div><ul style="list-style-type: none"><li>▪ RTX 4060 8GB</li><li>▪ WSL2 (Linux)</li><li>▪ CUDA fp16</li></ul></div></div> | <div><div>MODEL</div><div>模型</div><div><ul style="list-style-type: none"><li>▪ Stable Diffusion 1.5</li><li>▪ img2img + inpainting</li><li>▪ SD2 已从 HF 下架</li></ul></div></div> | <div><div>PARAMS</div><div>参数</div><div><ul style="list-style-type: none"><li>▪ <math>t \in \{50,150,300,500,700\}</math></li><li>▪ <math>strength = t / 1000</math></li><li>▪ <math>n\_base = 50</math></li></ul></div></div> | <div><div>DATA</div><div>数据</div><div><ul style="list-style-type: none"><li>▪ picsum 真实底图 64 张</li><li>▪ 512 × 512 分辨率</li><li>▪ → 1200 样本</li></ul></div></div> |
|-----------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------|

|                                   |                                   |                                 |
|-----------------------------------|-----------------------------------|---------------------------------|
| <div>生成耗时</div> <div>80 min</div> | <div>分析耗时</div> <div>30 min</div> | <div>总样本</div> <div>1,200</div> |
|-----------------------------------|-----------------------------------|---------------------------------|



# 核心结果:真实 vs Mock 代理

| Gate  | 真实 (Real)       | Mock 代理         | 差距 (Δ)     | 判定      |
|-------|-----------------|-----------------|------------|---------|
| gate0 | 0.688 / 0.643   | 0.631 / 0.758   | 方向一致       | PASS    |
| gate1 | 0.475 / ρ 0.476 | 0.757 / ρ 0.881 | mock +0.28 | WEAK    |
| gate2 | 0.372           | 0.454           | 校准尚可       | WEAK    |
| gate3 | +0.025          | +0.417          | mock +0.39 | PARTIAL |
| gate4 | —               | —               | —          | EVAL    |

## 核心发现

gate0 承重主线方向一致 → 真实残差信号可用;gate1/3 被 mock 严重高估,代理信号不可信

# 诚实解读

|                                                                                             |
|---------------------------------------------------------------------------------------------|
| <div>① gate0 过线但不豪华</div> <div>检测 AUC &lt; 0.7,且是 SD1.5 检 SD1.5 自家先验——最有利条件下的下界</div>       |
| <div>② gate1 被 mock 高估</div> <div>mock 把 strength 线性写进像素,真实 SDEdit 在低/高强度区间饱和,精细回归不可行</div> |
| <div>③ gate2 same ≈ cross 无信息量</div> <div>单模型设置下 same vs cross 本质相同,需第二个生成器才有判别意义</div>     |
| <div>④ gate3 跨生成器结构性不可测</div> <div>无 holdout 生成器 → 跨生成器增量无法评估;+0.025 不可解读</div>             |



# 过程中修复的 3 个 Bug

|                                                   |                                                                  |                                                                         |                                                             |
|---------------------------------------------------|------------------------------------------------------------------|-------------------------------------------------------------------------|-------------------------------------------------------------|
| <div>BUG-1</div> <div>Registry 不缓存 real 实例</div>  | <div>PROBLEM</div> <div>probe 每个样本重载扩散管线 → 上次实验中断的根因</div>       | <div>FIX</div> <div>registry 缓存 img2img / inpaint 实例,92 样本不再逐样本重载</div> | <div>IMPACT</div> <div>生成耗时 ~80 min (此前中断)</div>            |
| <div>BUG-2</div> <div>gate0 头部截断取样</div>          | <div>PROBLEM</div> <div>max_n 等间隔取样在放量后漏掉全部掩码样本</div>            | <div>FIX</div> <div>头部截断改为包含掩码样本的均匀取样</div>                             | <div>IMPACT</div> <div>localization 假 FAIL → 真实 0.643</div> |
| <div>BUG-3</div> <div>CAVEAT 文案不分 extractor</div> | <div>PROBLEM</div> <div>real extractor 被套用 multisigma 代理声明</div> | <div>FIX</div> <div>CAVEAT 按 extractor 类型区分,real 不再套用代理文案</div>         | <div>IMPACT</div> <div>报告准确性提升</div>                        |

# 结论与下一步

CONCLUSIONS

- ✓

残差可检测 / 可定位主线安全 (gate0 PASS)
- ✓

t<sub>0</sub> 精细回归降级 → 分桶方案
- ✓

mock 可验代码正确性,不可估效应量

局限

▪ 单一先验 (SD1.5)

▪ n\_base = 50 (样本偏少)

▪ 场景窄 (picsum 自然图)

NEXT STEPS

- P0

接入 SDXL 解锁跨生成器判定
- P0

gate1 桶边界敏感性 + 更强特征
- P1

扩底图规模 (>200 张)
- P1

真实 gate4 走完整 pipeline split